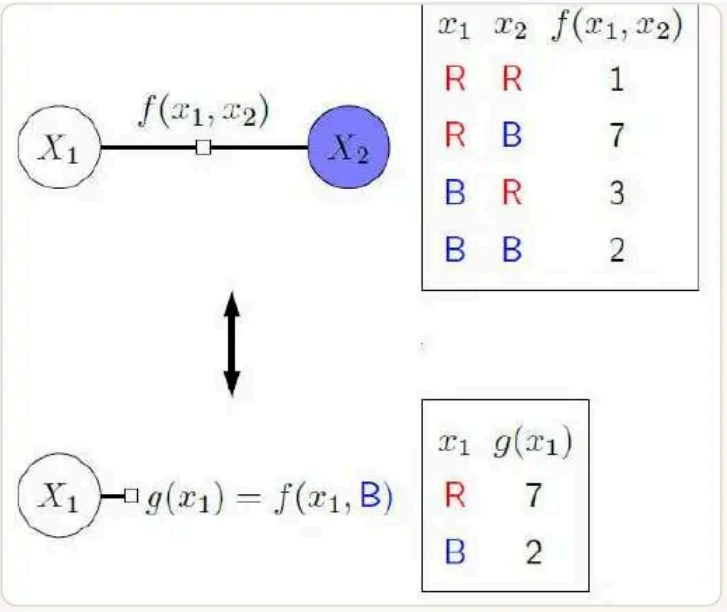
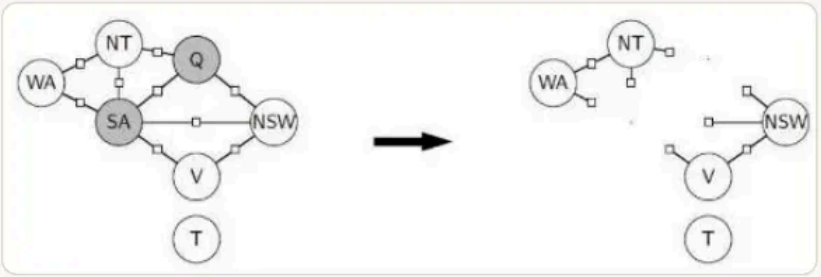


Conditioning: X_2=B 고정 → $f(x_1,x_2) \to g(x_1)$ (p.19)

Conditional Independence (조건부 독립) — A,B,C가 변수 분할. C에 조건화했을 때 A와 B가 독립이면 $A \perp B \mid C$.

- 동치 조건: A에서 B로 가는 *모든 경로*가 C를 통과
- 그래프적 검사: C를 제거했을 때 A-B 사이 경로가 없으면 성립



지도 채색: {WA,NT} ⊥ {V,NSW,T} | {SA,Q} (p.23)

Markov Blanket

p.24-26 · 최소 분리 집합

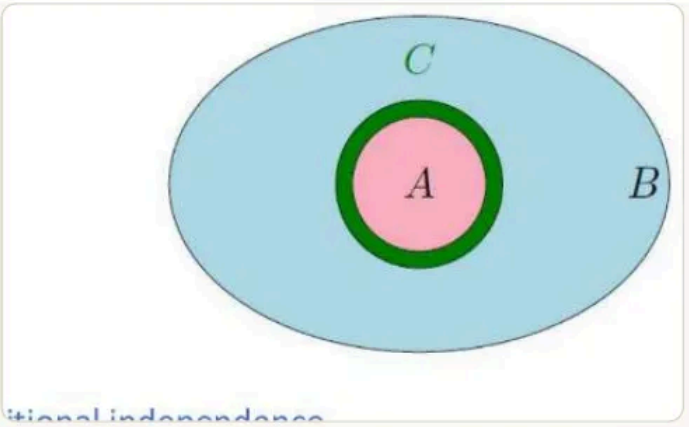
Q. Markov blanket의 정의는?

Q. 최소 분리 집합인 이유는?

Markov Blanket 정의 — 변수 부분집합 A ⊆ X의 MarkovBlanket(A) = A에 인접하지만 A 밖에 있는 모든 이웃.

A의 직접 이웃만 조건화하면 충분

- 형식: MarkovBlanket(A) = {v ∉ A | v와 A 사이에 edge 존재}
- C = MarkovBlanket(A), B = X \ (A ∪ C) 로 두면 $A \perp B \mid C$
- C는 A를 나머지로부터 *독립시키는 최소 집합*
- blanket이 작을수록 → factor graph 다루기 쉬움



Markov Blanket: A(분홍) 주위 C(녹색 링)가 B(파랑)로부터 분리 (p.25)

Markov Blanket 활용 — 지도 채색 — SA를 조건화하면 WA, NT, NSW, V가 서로 독립 → *각각 분리해서 최적화.*

- SA ∈ {R,G,B} 각 값에 대해: SA=v 고정 → 나머지 분리 → **각 부분 독립 최적화**
- 시간: 조건화 없이 3^n → 조건화 후 $3^1 \times$ (작은 서브그래프들)

> ✎ **핵심** Markov Blanket은 임의 노드 집합 A를 나머지 전체로부터 조건부 독립시키는 **최소 분리 집합**. $A \perp B \mid C$ (C=MarkovBlanket(A)) — 이 명제가 factor graph 효율화의 핵심.

CSP vs Markov Network 비교 p.13

Q. 0/1 팩터 vs 실수 팩터?

Q. 탐색 vs 확률추정 목적 차이?

개념	CSP (Constraint Satisfaction)	Markov Network
변수	Variables	Random Variables
가중치	Weights (Π factors)	P(X=x) = Weight(x)/Z
목표	Max weight assignment	Marginal $P(X_i=v)$
알고리즘	ICM (Iterated Cond. Modes)	Gibbs Sampling
수렴	Local optimum	Correct marginals*

Markov network = factor graph + 확률 정규화 (÷Z)

> ★ **필수암기** Markov network: P(X=x)=Weight(x)/Z, Z=partition function. Gibbs sampling: 각 변수를 조건부 분포로 재샘플링→주변확률 추정. A⊥B|C: C가 A→B 모든 경로 차단. MarkovBlanket(A)=A의 직접 이웃(A 제외)=최소 조건화 집합.

요약 Markov network = factor graph + **P(x)=Weight(x)/Z** 정규화 · Gibbs sampling으로 주변확률 추정 · A⊥B|C = C가 A-B 모든 경로 차단 · **Markov Blanket(A)=A를 분리하는 최소 이웃집합**.

Ch 14 Bayesian Networks 1 — 베이즈넷 기초

확률 복습 · BN 정의 · 확률적 추론 · Explaining Away · 확률적 프로그램

확률 복습 & Probabilistic Inference p.7-11

Q. joint·marginal·conditional 관계?

Q. inference query P(Q|E)란?

Q. Bayes rule의 형태는?

핵심 확률 법칙 — 모든 BN 추론의 수식 토대.

Chain rule이 BN 곱 공식의 기원

- **Joint probability**: P(A,B) = P(A∩B)
- **Conditional probability**: P(A|B) = P(A,B) / P(B)
- **Bayes rule**: P(A|B) = P(B|A)·P(A) / P(B)
- **Chain rule**: $P(X_1,\cdots,X_n) = \Pi_i P(X_i \mid X_1,\cdots,X_{i-1})$
- **Marginalization**: $P(X) = \Sigma_y P(X,Y=y)$ — 합산으로 숨은 변수 제거
- **Independence**: P(X,Y) = P(X)·P(Y)

Probabilistic Inference — 구조

- **Joint distribution**: 전 변수 결합 확률 $P(X_1,\cdots,X_n)$ — '확률적 데이터베이스'
- **Evidence** E=e: 관측된 변수 집합에 값 고정
- **Query** Q: 알고 싶은 변수 집합
- **Hidden** H: evidence도 query도 아닌 나머지 — **marginalize out**
- 출력: `P(Q | E=e)` — 사후 분포

> ✎ **핵심** 도전 과제: **n개 변수 joint = 크기 지수**적. BN은 **조건부 독립**을 이용해 compact하게 표현 → joint를 local CDP 곱으로 분해.

Bayesian Network 정의 p.12-14, 17-18

Q. BN factorization 식은?

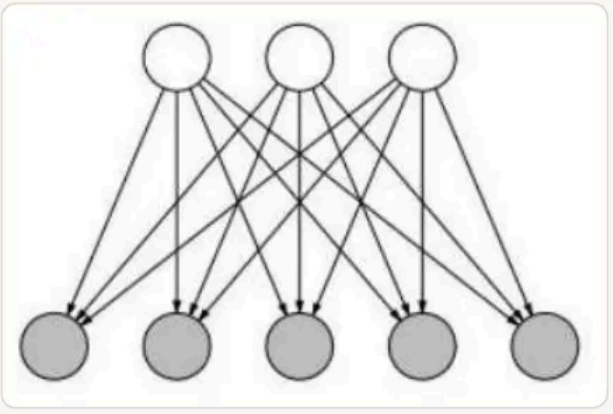
Q. DAG + local CPD의 의미는?

Q. joint를 어떻게 분해?

Bayesian Network (BN) — 변수들의 **조건부 독립 구조**를 DAG로 인코딩한 확률 모델.

LCD 하나 = factor graph의 하나의 factor

- 노드 = 확률 변수, 유향 간선 = 직접 영향(부모→자식)
- 각 노드 X_i에 **local conditional distribution** $p(x_i \mid x_Parents(i))$ 부여
- **Joint = LCD들의 곱**: $P(X_1=x_1,\cdots,X_n=x_n) = \prod_i p(x_i \mid x_Parents(i))$
- DAG ⟹ 사이클 없음 → topological order가 존재

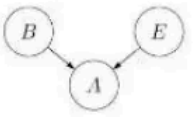


BN 구조 — DAG (p.17)

Alarm 예제 — BN 구체화 — 변수: B(burglary), E(earthquake), A(alarm). 구조: B→A, E→A.

- p(b): B의 prior (파라미터 ε)
- p(e): E의 prior (파라미터 ε)
- p(a|b,e): CPT — `p(a|b,e) = [a = (b ∨ e)]` (OR 게이트)
- Joint: $P(B=b,E=e,A=a) \equiv p(b)\cdot p(e)\cdot p(a|b,e)$

$$\mathbb{P}(B=b,E=e,A=a) \equiv p(b)p(e)p(a|b,e)$$



b	$p(b)$
1	ϵ
0	$1-\epsilon$

e	$p(e)$
1	ϵ
0	$1-\epsilon$

b	e	a	$p(a\|b,e)$
0	0	0	1
0	0	1	0
0	1	0	0
0	1	1	1
1	0	0	0
1	0	1	1
1	1	0	0
1	1	1	1

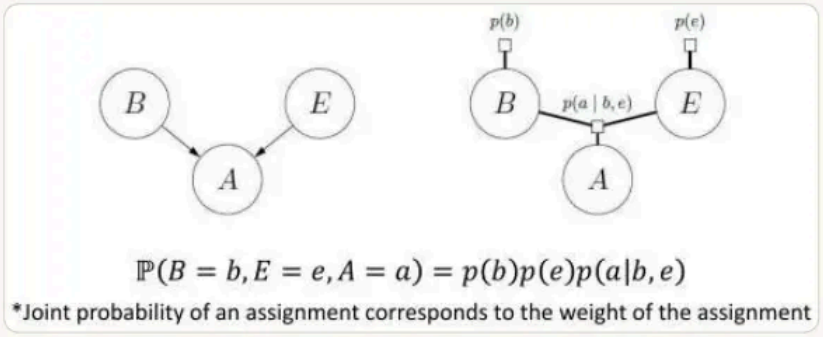
$$p(b) = \epsilon\cdot[b=1] + (1-\epsilon)\cdot[b=0]$$
$$p(e) = \epsilon\cdot[e=1] + (1-\epsilon)\cdot[e=0]$$
$$p(a|b,e) = [a = (b \vee e)]$$

*A local conditional distribution p corresponds to a factor

Alarm BN — DAG + CPT 전체 (p.12)

BN vs Factor Graph

- Factor graph: 변수 노드 + factor 노드(사각형) → 모든 인수의 곱
- BN: local conditional distribution = factor의 특수 케이스
- 결론: BN ⊂ Factor Graph — BN은 factor graph의 특수한 경우
- Assignment의 joint prob = assignment의 weight (factor graph 해석)



$$\mathbb{P}(B=b,E=e,A=a)=p(b)p(e)p(a|b,e)$$

*Joint probability of an assignment corresponds to the weight of the assignment

Alarm BN ↔ Factor Graph 대응 (p.13)

Probabilistic Inference & Explaining Away p.9-11, 14-16

Q. explaining away 현상은?

Q. v-structure에서 의존 발생 조건?

Q. 조건화 전후 독립성 변화?

Alarm 예제 — 추론 계산

marginalize로 E 또는 B를 합산 제거

- P(A=1) = ε(1−ε) + ε = 2ε−ε² (B=1 or E=1일 때 A=1)
- P(B=1|A=1) = ε/(2ε−ε²) → 알람이 울리면 burglary 의심↑
- P(B=1|A=1,E=1) = ε²/(ε)·… → 지진이 밝혀지면 burglary 의심↓

Explaining Away — 설명 소거 — 두 원인이 하나의 효과를 양의 방향으로 유발할 때, 효과를 조건화한 상태에서 한 원인이 밝혀지면 다른 원인의 확률이 감소한다.

- P(B=1|A=1) > P(B=1|A=1, E=1) — E가 A를 '설명'해 버리면 B는 덜 필요
- 중요: 두 원인 B, E는 서로 독립임에도 A를 조건화하면 조건부 의존 발생
- 의학 진단: 기침+가려운 눈 → 감기 or 알레르기? 하나가 확인되면 다른 하나 확률 감소

⚠ **함정** Explaining away는 원인 변수들이 독립이더라도 발생한다 — 조건화(conditioning)가 독립성을 깨뜨림. 'Effect를 관측'하면 원인들 사이에 v-structure 의존이 생김.

시나리오	P(B=1|…)
A=1 만 관측	ε/(2ε−ε²) > ε
A=1, E=1 관측	ε² / ε = ε (원래 prior와 같음)

Alarm 예제: 지진(E=1)이 알람을 설명하면 burglary 확률 → prior로 복귀

Probabilistic Programs & 모델 분류 p.21-29

Q. 생성 스토리(generative)란?

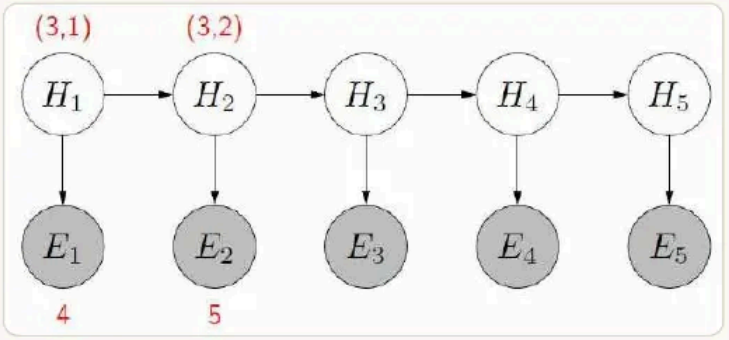
Q. HMM·Naive Bayes·LDA 분류 기준?

Probabilistic Program — BN을 랜덤화 프로그램으로 표현. 프로그램이 실행되면서 확률 변수들을 샘플링.

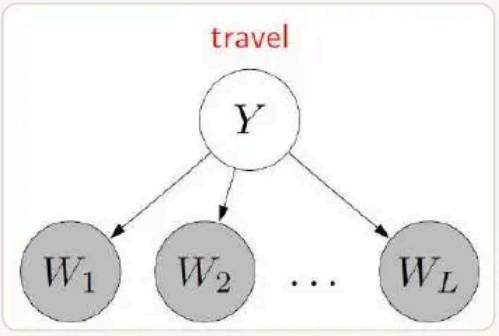
- Bernoulli(ε): random() < ε이면 1, 아니면 0
- 프로그램 구조 → BN 구조 (반복문 = 체인/격자 구조 생성)
- 패러다임: 생성 스토리 — 잠재 변수(출력)가 관측(입력)을 생성
- 일반 분류(입력→출력)와 반대 방향!

모델	Probabilistic Program 구조	BN 구조	Inference 질문
Markov Model	For t: $W_t \sim p(W_t \mid W_{t-1})$	$X_1 \to X_2 \to \cdots \to X_n$ 체인	문장 확률 스코어링
HMM	For t: $H_t \sim p(H \mid H_{t-1})$, $E_t \sim p(E \mid H_t)$	H 체인 + E 관측 레이어	센서→실제 위치
Factorial HMM	For t,k: $H_t^k \sim p$, $E_t \sim p(E \mid H\text{^}a, H\text{^}b)$	두 H 체인 + 공유 E	복수 객체 추적
Naive Bayes	$Y \sim p(Y)$; $W_i \sim p(W \mid Y)$	Y 루트 → $W_1 \cdots W_L$	문서→카테고리
LDA	$\alpha \sim \text{Dir}$; $Z_i \sim p(Z \mid \alpha)$; $W_i \sim p(W \mid Z_i)$	토픽 혼합 + 단어	문서→토픽 분포

주요 BN 모델 비교 — 생성 스토리 구조 차이



HMM BN — H 체인 + 관측 E (p.24)



Naive Bayes BN — Y가 모든 W 생성 (p.26)

★ 필수암기 BN = DAG + local conditional distributions 곱. Joint = Π_i p(x_i|x_Parents(i)). Explaining away: 독립 원인도 effect 조건화하면 의존. BN ⊂ Factor Graph. Probabilistic program → 생성 스토리 → BN 구조 자동 결정.

요약 BN = DAG + local conditional 곱 Π_i p(x_i|x_Parents(i)) · Explaining away: 독립 원인도 공통 effect 조건화하면 v-structure 의존 발생 · probabilistic program → 생성 스토리 → 모델 분류(HMM·NB·LDA).

Ch 15 Bayesian Networks 2 — HMM 추론

일반 추론 전략 · Forward-Backward · Particle Filtering

Bayesian Network & Inference 리뷰 p.3-6

Q. BN 추론에서 묻는 것은?

Q. joint→query 환원 흐름은?

Bayesian Network 정의 — 랜덤변수 $X=(X_1,\cdots,X_n)$에 대한 DAG — 노드별 조건부분포의 곱으로 결합분포를 표현.

- 결합분포: $\mathbb{P}(X_1,\cdots,X_n) = \Pi_i\, p(X_i \mid \text{parents}(X_i))$
- Markov network 관계: Bayes net = Markov net with normalizer Z=1

확률적 추론 문제 — 입력: BN + evidence E=e + query Q. 출력: $\mathbb{P}(Q \mid E=e)$.

- 예시: 기침(H=1)·가려운눈(I=1) → 감기(C=c)일 확률 = $\mathbb{P}(C \mid H=1, I=1)$
- Evidence 조건화: 관측된 변수를 특정값으로 고정 → 잔여 네트워크만 추론

Markov network로 환원 — BN에서 evidence 조건화 후 Markov network 공식으로 변환.

- Z^{-1} 인자(정규화상수)를 곱해 사후분포 계산 가능
- **Unobserved leaves 제거**: 쿼리와 무관한 **관측되지 않은 leaf 노드**는 marginalize 후 버림 — 추론 전에 제거
- **Disconnected components 제거**: evidence·query와 **단절된 컴포넌트**는 독립 → 추론 전 버림

일반 확률적 추론 전략 p.7-10

Q. 추론 5단계 절차는?

Q. leaf·단절 노드 제거 근거는?

Q. Markov net으로 왜 변환?

General Probabilistic Inference Strategy

```
Input: BN ℙ(X₁,…,Xₙ),  evidence E=e,  query Q
1. Condition on evidence  (evidence 변수를 관측값으로 고정)
2. Throw away unobserved leaves  (비관측 leaf 노드 제거)
3. Throw away disconnected components  (단절 컴포넌트 제거)
4. Define Markov network out of remaining factors
5. Run inference algorithm  (예: manual, Gibbs sampling, …)
```

단계 2·3을 반복 적용해 네트워크를 최대한 축소한 뒤 추론 → 비용 절감

✎ **핵심** 단계 2: 관측 없는 leaf를 제거하면 그 부모의 인자가 marginalize-out됨. 단계 3: query·evidence와 **연결이 없는** 변수는 결과에 영향 없음 → 버려도 $\mathbb{P}(Q|E=e)$ 불변.

Hidden Markov Model (HMM) p.12-13

Q. transition·emission factor는?

Q. lattice(trellis) 구조란?

Q. filtering vs smoothing?

HMM 구조 (object tracking 예시) — 숨은 상태 $H_1,\cdots,H_n$ ↔ 관측 $E_1,\cdots,E_n$. 결합분포를 세 인자로 인수분해.

초기·전이·방출 세 인자

- $\mathbb{P}(H=h, E=e) = p(H_1) \cdot \prod p(H_i|H_{i-1}) \cdot \prod p(E_i|H_i)$
- **초기분포** $p(H_1)$ · **전이분포** $p(H_i|H_{i-1})$ · **방출분포** $p(E_i|H_i)$

HMM 추론 질문 유형

- **Filtering**: $\mathbb{P}(H_i \mid E_1=e_1, \cdots, E_i=e_i)$ — 현재까지 관측만 사용
- **Smoothing**: $\mathbb{P}(H_i \mid E_1=e_1, \cdots, E_n=e_n)$ — 미래 관측까지 전부 사용
- Filtering = Smoothing의 특수 경우 (미래 관측 → unobserved leaf → 제거)

Forward-Backward Algorithm p.14-16

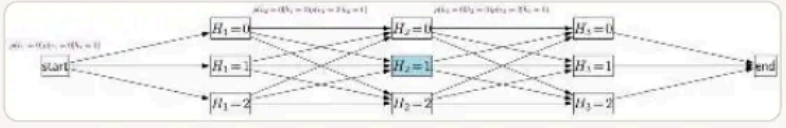
Q. forward F_i·backward B_i 정의?

Q. marginal을 어떻게 합성?

Q. 복잡도 $O(n|D|^2)$ 구성은?

Lattice 표현 — 변수 기반 BN → **상태 기반 격자** (각 상태 = 변수의 특정 값)로 변환.

- Edge start → $H_1=h_1$의 가중치 = $p(H_1=h_1)\cdot p(E_1|H_1=h_1)$
- Edge $H_i=h_i \to H_{i+1}=h_{i+1}$의 가중치 = $p(h_i|h_{i-1})\cdot p(e_i|h_i)$
- **start→end 경로 하나 = 하나의 complete assignment** (가중치 = 경로 상의 모든 edge weight의 곱)
- $\mathbb{P}(H_i=h_i \mid E=e)$ = $H_i=h_i$를 지나는 경로의 가중합 비율



Lattice 표현: 각 열이 H_i의 값들, 경로=assignment (p.14)

Forward·Backward 메시지 — 경로 합산을 동적프로그래밍으로 효율화 — 두 방향 메시지 정의.

F: 좌→우
B: 우→좌
S: 곱

- Forward $F_i(h_i) = \Sigma_{\{h_{i-1}\}} F_{i-1}(h_{i-1})\cdot \text{Weight}(H_{i-1}=h_{i-1}, H_i=h_i)$
- → **start부터 $H_i=h_i$까지의 경로 가중합**
- Backward $B_i(h_i) = \Sigma_{\{h_{i+1}\}} B_{i+1}(h_{i+1})\cdot \text{Weight}(H_i=h_i, H_{i+1}=h_{i+1})$
- → **$H_i=h_i$부터 end까지의 경로 가중합**
- $S_i(h_i) = F_i(h_i)\cdot B_i(h_i)$ — start부터 end까지 *$H_i=h_i$를 통과하는* 경로 가중합